

课程设计论文

2023/5/23

目录

1 引言	1
2 方法论	2
3 加速算法与增强模型	3
4 去噪测试	4
5 超分辨测试	5

最优化课程报告

摘要

复现了一个低光增强模型，给出了几种去噪对比与超分辨的结果。

关键词 图像处理 低光增强 图片去噪 图像超分辨

1 引言

当在低光条件下捕捉图像时，图像往往会受到低能见度的影响。除了降低图像的视觉美感外，这种低质量还可能严重降低许多主要针对高质量输入设计的计算机视觉和多媒体算法的性能。高可见度的图像反映了目标场景的清晰细节，这对于许多基于视觉的技术至关重要，如目标检测和跟踪。然而，在低光条件下拍摄的图像通常可见度较低。低光条件下拍摄的图像的视觉质量较差，且会影响那些主要针对高可见度输入设计的算法的性能。图1提供了几个这样的例子，许多细节被掩埋在黑暗中，需要进行低光图像增强。

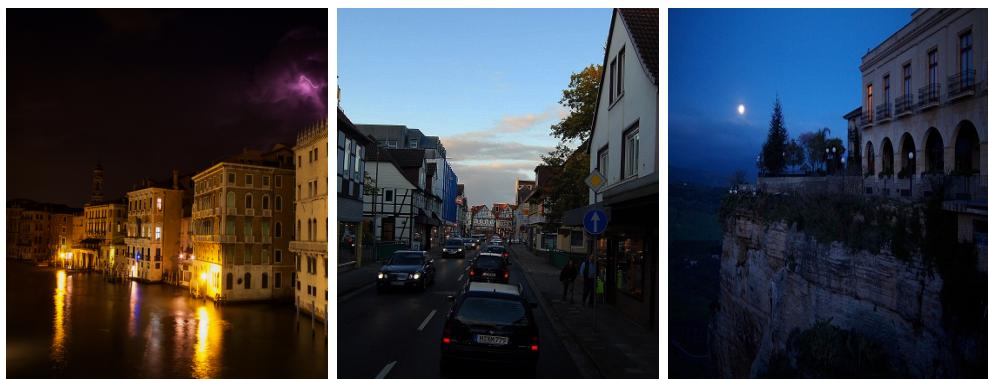


图 1 低光照原图

直接增强低光图像像素亮值是提高暗区可见性最直观和最简单的方法。然而，这个操作会使得相对较亮的区域饱和，从而丢失相应的细节。直方图均衡化策略可以通过某种方式强制输出图像落在范围 $[0, 1]$ 内来避免上述问题。本质上，它们侧重于对比度增强，而不是利用真实的照明原因，存在过度增强和过度减弱的风险。另一种解决方案是伽马校正，它是对图像进行的非线性操作。主要缺点是伽马校正的非线性操作是对每个像素单独进行的，而不考虑某个像素与其邻域的关系，因此可能使增强结果脆弱且与真实场景不一致。图2展示了直接增强的结果。



图 2 k 倍放大亮度的图像, $k = 2$

2 方法论

在 Retinex 理论 [2] 中, 假设彩色图像可以分解为两个因素, 反射率和照明.

$$\mathbf{L} = \mathbf{R} \circ \mathbf{T}, \quad (2.1)$$

其中, \mathbf{L} 和 \mathbf{R} 分别表示捕获的图像和期望的恢复图像. 此外, \mathbf{T} 表示光照图, 操作符 \circ 表示逐元素相乘. 由于分解问题的病态性, 需要更多的先验知识来约束解的空间. 但是, 如果任务仅是为了提亮低光照图像, 就没有必要将输入图像分解为两个组成部分. 因为有 $\mathbf{R} = \mathbf{L}/\mathbf{T}$, 其中除法逐元素进行. 估计 \mathbf{T} , 随后 $\mathbf{L}/\hat{\mathbf{T}}$ 可以直接作为光照增强的结果.

选择以下初始估计处理非均匀光照:

$$\hat{\mathbf{T}}(x) \leftarrow \max_{c \in \{R, G, B\}} \mathbf{L}^c(x), \quad (2.2)$$

此初始估计使得图像不会过饱和, 如果选择 \min 函数, 则过饱和. 以及, 选定此初值是为了非均匀增强低光照图像的光照, 因此接下来的全程均不会消除光源引起的色偏.

选定初值后的优化模型 [3] 为

$$\min_{\mathbf{T}} \|\hat{\mathbf{T}} - \mathbf{T}\|_F^2 + \alpha \|\mathbf{W} \circ \nabla \mathbf{T}\|_1, \quad (2.3)$$

其中 α 是平衡两个项的系数, $\|\cdot\|_F$ 和 $\|\cdot\|_1$ 分别表示 Frobenious 范数和 ℓ_1 范数. 此外, \mathbf{W} 是权重矩阵, $\nabla \mathbf{T}$ 是一阶导数滤波器. 使用交替优化方法可以获得迭代式.

$$\begin{aligned} \mathbf{T}^{(t+1)} &\leftarrow \operatorname{argmin}_{\mathbf{T}} \|\hat{\mathbf{T}} - \mathbf{T}\|_F^2 + \Phi(\mathbf{Z}^{(t)}, \nabla \mathbf{T} - \mathbf{G}^{(t)}) . \\ \mathbf{G}^{(t+1)} &\leftarrow \operatorname{argmin}_{\mathbf{G}} \alpha \|\mathbf{W} \circ \mathbf{G}\|_1 + \Phi(\mathbf{Z}^{(t)}, \nabla \mathbf{T}^{(t+1)} - \mathbf{G}) . \end{aligned} \quad (2.4)$$

求导后可以得到

$$\begin{aligned} \mathbf{T} &= (2\mathbf{I} + \mu^{(t)} \mathbf{D}^T \mathbf{D})^{-1} \left(2\hat{\mathbf{T}} + \mu^{(t)} \mathbf{D}^T (\mathbf{G}^{(t)} - \frac{\mathbf{Z}^{(t)}}{\mu^{(t)}}) \right), \\ \mathbf{G}^{(t+1)} &= \mathcal{S}_{\frac{\alpha \mathbf{W}}{\mu^{(t)}}} \left[\nabla \mathbf{T}^{(t+1)} + \frac{\mathbf{Z}^{(t)}}{\mu^{(t)}} \right], \\ \mathbf{Z}^{(t+1)} &\leftarrow \mathbf{Z}^{(t)} + \mu^{(t)} (\nabla \mathbf{T}^{(t+1)} - \mathbf{G}^{(t+1)}); \\ \mu^{(t+1)} &\leftarrow \mu^{(t)} \rho, \rho > 1. \end{aligned} \quad (2.5)$$

其中 $\mathcal{S}_{\varepsilon>0}[\cdot]$ 表示收缩算子. 写为算法即为

Algorithm 1 照明估计迭代

```

输入: 初值  $\alpha$ , 权重矩阵  $\mathbf{W}$ , 照明初始估计  $\hat{\mathbf{T}}$ ;
初始化:  $\mathbf{T}^{(0)} = \mathbf{O}^{m \times n}$ ,  $\mathbf{G}^{(0)} = \mathbf{Z}^{(0)} = \mathbf{O}^{2m \times n}$ ,  $t = 0$ ,  $\mu^{(0)} > 0$ ,  $\rho > 1$ ;
while 未达到指定循环次数时 do
    更新  $\mathbf{T}^{(t+1)}$ , 使用(2.5);
    更新  $\mathbf{G}^{(t+1)}$ , 使用(2.5);
    更新  $\mathbf{Z}^{(t+1)}$ , 使用(2.5);
     $t = t + 1$ ;
end while
输出:  $T = T^{(t)}$ ;

```

复现的 PSNR 和 SSIM 数值并不理想, PSNR 值没有超过 30, 而 SSIM 以灰度图计算在 80 至 95 区间浮动.

3 加速算法与增强模型

由于

$$\lim_{\epsilon \rightarrow 0^+} \sum_x \sum_{d \in \{h, v\}} \frac{\mathbf{W}_d(x) (\nabla_d \mathbf{T}(x))^2}{|\nabla_d \mathbf{T}(x)| + \epsilon} = \|\mathbf{W} \circ \nabla \mathbf{T}\|_1,$$

因而可以使用 $\sum_x \sum_{d \in \{h, v\}} \frac{\mathbf{W}_d(x) (\nabla_d \mathbf{T}(x))^2}{|\nabla_d \mathbf{T}(x)| + \epsilon}$ 近似 $\|\mathbf{W} \circ \nabla \mathbf{T}\|_1$. 此时, 问题(2.3)改写为

$$\min_{\hat{\mathbf{T}}} \|\hat{\mathbf{T}} - \mathbf{T}\|_F^2 + \alpha \sum_x \sum_{d \in \{h, v\}} \frac{\mathbf{W}_d(x) (\nabla_d \mathbf{T}(x))^2}{|\nabla_d \hat{\mathbf{T}}(x)| + \epsilon}. \quad (3.1)$$

这个模型的解为

$$t = \left(I + \sum_{d \in \{h, v\}} D_d^T \text{Diag}(a_d) D_d \right)^{-1} \hat{t}, \quad (3.2)$$

小写字母表示向量化, $a_d = \alpha \circ W \circ (\left| \nabla_d \hat{L}(x) \right| + \epsilon)^{-1}$ 是权重. 文献 [5] 有现成的求解方法.

加速的求解方法(3.2)导出了修改的模型(3.3)

$$L = R \circ T + N, \quad (3.3)$$

其中 N 表示噪声. 由噪声抑制模型导出的优化问题为

$$\begin{aligned} \arg \min_{R, \hat{R}} \mathcal{L}(R, \hat{R}, Z) = & \|R \circ T - L\|_F^2 + \omega \sum_i \|NN_i(R)\|_* \\ & + \beta \|\nabla \hat{R} - G\|_F^2 + Z \circ (\hat{R} - R) \\ & + \frac{\mu}{2} \|\hat{R} - R\|_F^2, \end{aligned} \quad (3.4)$$

其中 T 是使用(3.2)迅速求解获得的最优照明参数, 并且全局只求解一次.

图组3展示了 [3] 和 [4] 结果的对比, 当然, 在对比度上有一些差别, 但重要的是 LR3M 虽然对噪声做了估计处理, 但严重损失了清晰度, 从这一点来说, LR3M 算法高额的计算时长 (以分钟计数) 代价得不偿失.



图 3 LIME 与 LR3M 对照

4 去噪测试

文献 [3] 提出的低光增强模型的缺点在于没有复合去噪方法, 而 [4] 的方法虽然对噪声做了抑制, 但计算成本过高. 一个合适的方法是 [3] 中所提到的 BM3D[7] 去噪方法. 图组4展示了去噪前后的区别.



图 4 LIME: 原图与 BM3D 去噪对比

常见的图片去噪方法还有中值滤波与小波去噪, 图组5展示了结果.



图 5 中值滤波与小波去噪效果对比

从图片的展示结果来看, 中值滤波产生了色偏, 而小波去噪的效果则较弱. 实际而言,[3] 中并非没有考虑到噪声问题, 在权重矩阵的设置上 (也就是迭代的初值设计),[3] 的作者采用的高斯核权重矩阵

$$\begin{aligned} \mathbf{W}_h(x) &\leftarrow \sum_{y \in \Omega(x)} \frac{G_\sigma(x, y)}{\left| \sum_{y \in \Omega(x)} G_\sigma(x, y) \nabla_h \hat{\mathbf{T}}(y) \right| + \epsilon} \\ \mathbf{W}_v(x) &\leftarrow \sum_{y \in \Omega(x)} \frac{G_\sigma(x, y)}{\left| \sum_{y \in \Omega(x)} G_\sigma(x, y) \nabla_v \hat{\mathbf{T}}(y) \right| + \epsilon} \end{aligned} \quad (4.1)$$

实际上具有一定的滤波效果.

5 超分辨率测试

[3] 主要解决的问题是低光增强，也就是图片的细节增强。同样属于细节增强方向的图像增强领域还有图像的超分辨。技术上，近年来的深度学习超分辨方法已经获得了非常良好的成果。并且在 [8] 有 [3] 的深度学习增强模型实现，对于过饱和问题做了对抗处理。图组6是不同超分辨数据集导出的增强图片。



图 6 两组深度学习超分辨图像

第一组采用的是 MATLAB 自带的 VDSR 超分辨数据网络训练，第二组的结果来自 supare 在线网站。相比较而言，两组的成果均使得图片的清晰度有了改善，而在线网站的结果则附带了去噪效果。

注释：图片和文档位于 https://github.com/wudizhe001/OP_NUIST_CourseReport.

参考文献

- [1] Jingye Chen. Scene Text Telescope: Text-Focused Scene Image Super-Resolution.
- [2] E. Land, "The retinex theory of color vision," *Scientific American*, vol. 237, no. 6, pp. 108–128, 1977.
- [3] X. Guo, Y. Li, and H. Ling, "LIME: Low-light image enhancement via illumination map estimation," *IEEE Trans. Image Process.*, vol. 26, no. 2, pp. 982–993, Feb. 2017.
- [4] X. Ren, W. Yang, W. -H. Cheng and J. Liu, "LR3M: Robust Low-Light Enhancement via Low-Rank Regularized Retinex Model," in *IEEE Transactions on Image Processing*, vol. 29, pp. 5862–5876, 2020.
- [5] Bhavya Vasudeva, Puneesh Deora, "Report: Low-light Image Enhancement".
- [6] Dongwei Ren, Hongzhi Zhang, David Zhang, Wangmeng Zuo, "Fast total-variation based image restoration based on derivative alternated direction optimization methods," *Neurocomputing*, Volume 170, 2015, Pages 201-212.
- [7] K. Dabov, A. Foi, V. Katkovnik, and K. Egiazarian, "Image denoising by sparse 3d transform-domain collaborative filtering," *TIP*, vol. 16, no. 8, pp. 2080–2095, 2007.
- [8] Zhang, Yonghua and Zhang, Jiawan and Guo, Xiaojie, Kindling the Darkness: A Practical Low-light Image Enhancer.