

最优化课程设计:"LIME 论文复现 "

代码环境:"R7000P 2020,Windows 11,MATLAB 2023a"

参考文献

%[1]是基础参考论文,[2]比较高级,还没看,[3]是全部代码和思路的主要参考文献,[4]为[3]提供了补充.

[1] X. Guo, Y. Li, and H. Ling, "LIME: Low-light image enhancement via illumination map estimation," *IEEE Trans. Image Process.*, vol. 26, no. 2, pp. 982–993, Feb. 2017.

[2] X. Ren, W. Yang, W. -H. Cheng and J. Liu, "LR3M: Robust Low-Light Enhancement via Low-Rank Regularized Retinex Model," in *IEEE Transactions on Image Processing*, vol. 29, pp. 5862-5876, 2020.

[3] Bhavya Vasudeva, Puneesh Deora, "Report:Low-light Image Enhancement".

[4] Dongwei Ren, Hongzhi Zhang, David Zhang, Wangmeng Zuo, "Fast total-variation based image restoration based on derivative alternated direction optimization methods," *Neurocomputing*, Volume 170, 2015,Pages 201-212.

第 1 部分 初始化

首先,读取测试图片.MATLAB 自带的"imshow"函数用于展示图片.

```
clear;  
img = imread('test.jpg');  
imshow(img);
```



将图像双精度化.(我不知道这是为什么.不过,这和全文的主线内容无关,只不过是代码层面的细节)

```
img = im2double(img);  
%imshow(img);
```

1.1 光照模型的公式

用到的理论公式是

$$\mathbf{L} = \mathbf{R} \circ \mathbf{T},$$

其中 \mathbf{L} 是拍摄图片,而 \mathbf{R} 是希望恢复的图像, \mathbf{T} 是照明图.注意,这里的 \circ 符号表示逐元素的乘法,用图像处理的术语来说,是所谓的逐像素点增强.在 MATLAB 的代码实现里,表现为需要使用 `.*` 而并非 `*`.

参数 \mathbf{L} 是已知的,问题在于如何获得合理的 \mathbf{T} 值以便恢复图像.

1.2 初始照明的估计

由于方法论部分是使用最优化方法得到最优参数 T ,因此首先要解决的问题是选定 T 的初值 \hat{T} .

这里选定 RGB 三通道的极值作为初值使用,理由来自所谓的"非均匀光照提升".数学上,可以写作

$$\hat{T}(x) \leftarrow \max_{c \in \{R,G,B\}} \mathbf{L}^c(x),$$

其中 x 是像素点.

使用自定义的"myLighting"函数获取初始照明图"testImg",函数具体定义则位于实时脚本文件的底部.之后类似的以"my"开头的函数均是自定义的,不再说明.其中"ini_map"是二维矩阵,其等同于"testImg"的灰色图像,理由则是所谓的"三通道共享光照",也就是默认照明图像 \mathbf{T} 的 RGB 三通道数值相同.这种理论确实有好处,因为如此一来便无需处理三维的彩色图像矩阵,而只需考虑二维的照明矩阵.

```
[testImg,ini_map] = myLighting(img);  
%imshow(testImg);
```

1.3 DEMO NOW

这里给出初步的结果测试.

```
alpha=0.27;  
mu0=0.2;  
rho=1.2;  
[T] = myTrial(ini_map, alpha, mu0, rho);  
%R=repmat(T,[1,1,3]);  
newT=gammaResult(T,0.8);  
newT=repmat(newT,[1,1,3]);  
newR=img./newT;  
imshow(newR);
```



```
PSNRval=psnr(newT(:,:,1),T);  
[ssimval, ~] = ssim(newT(:,:,1), T);  
disp([PSNRval,ssimval]);
```

23.2360 0.9313

```
R2=adjustImage(newR,0.9);
```



```
imshow(R2);
```



```
demo1=imread('building.bmp');  
demo2=imread('cars.bmp');  
[I1]=quickDemo(demo1, alpha, mu0, rho);
```



```
[I2]=quickDemo(demo2, alpha, mu0, rho);
```




```
function outImage=quickDemo(newimg, alpha, mu0, rho)
    newimg = im2double(newimg);
    [~,ini_map] = myLighting(newimg);
    [T] = myTrial(ini_map, alpha, mu0, rho);
    newT=gammaResult(T,0.8);
    newT=repmat(newT,[1,1,3]);
    outImage=newimg./newT;
    imshow(outImage);
end
function outImage = adjustImage(inImage, k1)
    % 将输入的 RGB 图像转换为 HSV 图像
    hsvImage = rgb2hsv(inImage);
    % 降低饱和度
    hsvImage(:, :, 2) = hsvImage(:, :, 2) * k1;
    % 将 HSV 图像转回 RGB 图像
    outImage = hsv2rgb(hsvImage);
    imshow(outImage);
end
```

第 2 部分 最优化参数

在上一部分从图像 \mathbf{L} 中抽离出核心关键照明矩阵 \mathbf{T} 后,这一部分的基本问题是

$$\min_{\mathbf{T}} \|\hat{\mathbf{T}} - \mathbf{T}\|_F^2 + \alpha \|\mathbf{W} \circ \nabla \mathbf{T}\|_1.$$

其中 α 是预先指定的平衡系数,而 \mathbf{W} 则是预先设置的权重矩阵.看起来,这是经典的 LASSO 问题.

将上式调整为等价的优化问题

$$\min_{\mathbf{T}, \mathbf{G}} \|\hat{\mathbf{T}} - \mathbf{T}\|_F^2 + \alpha \|\mathbf{W} \circ \mathbf{G}\|_1 \quad \text{s.t.} \quad \nabla \mathbf{T} = \mathbf{G}.$$

在此式中使用增广乘子方法,最终导出以下优化问题:

$$\arg\min_{\mathbf{T}, \mathbf{G}} \min_{\mathbf{Z}} \mathcal{L}(\mathbf{T}, \mathbf{G}; \mathbf{Z}) := \|\hat{\mathbf{T}} - \mathbf{T}\|_F^2 + \alpha \|\mathbf{W} \circ \mathbf{G}\|_1 + \Phi(\mathbf{Z}, \nabla \mathbf{T} - \mathbf{G}),$$

其中 $\Phi(\mathbf{Z}, \nabla \mathbf{T} - \mathbf{G}) = \frac{\mu}{2} \|\nabla \mathbf{T} - \mathbf{G}\|_F^2 + \langle \mathbf{Z}, \nabla \mathbf{T} - \mathbf{G} \rangle$, 这里 $\langle \cdot, \cdot \rangle$ 表示矩阵内积, μ 是一个正的惩罚标量, $\mathbf{Z} = \mathbf{Z}(\mathbf{T}, \mathbf{G})$ 是乘子变量.

现在要求解 $\min \mathcal{L}$,就要获得 $\arg \min \mathcal{L}$ 对应的三个最优参数 $\mathbf{T}, \mathbf{G}, \mathbf{Z}$.即将使用的求解器是交替方向乘子法,也就是将最优问题关于 \mathbf{T}, \mathbf{G} 分步优化.至于 \mathbf{Z} ,将会在前两个参数分步优化时一并迭代更新.

2.1 T 子问题

首先需要确定 \mathbf{T} 参数是如何迭代的.这是因为 \mathbf{G} 参数的迭代需要用到 \mathbf{T} 参数迭代后的数值.

2.1.1 公式的导出

收集涉及 \mathbf{T} 的项,可以得到以下问题:

$$\mathbf{T}^{(t+1)} \leftarrow \arg\min_{\mathbf{T}} \|\hat{\mathbf{T}} - \mathbf{T}\|_F^2 + \Phi(\mathbf{Z}^{(t)}, \nabla \mathbf{T} - \mathbf{G}^{(t)}).$$

这是一个经典的最小二乘问题,通过对 \mathbf{T} 求导来计算解.求导的结果是

$$2(\mathbf{T} - \hat{\mathbf{T}}) + \mu^{(t)} \mathbf{D}^T (\mathbf{D} \mathbf{T} - \mathbf{G}^{(t)}) + \mathbf{D}^T \mathbf{Z}^{(t)} = 0,$$

当然,按照此前说明的,这里 $\nabla \mathbf{T} = \mathbf{D} \mathbf{T}$.以及,矩阵 $\mathbf{D} = \begin{bmatrix} \mathbf{D}_h \\ \mathbf{D}_v \end{bmatrix}$ 包含 \mathbf{D}_h 和 \mathbf{D}_v ,是离散的梯度近似矩阵,具体地说,是两个使用前向差分法获得的 Toeplitz 矩阵.不过,数值算子 \mathbf{D} 并不能直接作用于矩阵 \mathbf{X} ,要经过如下的一个简单变换

$$\mathbf{D}(\mathbf{X}) \leftarrow \text{reshape}(\mathbf{D}(\text{vec}(\mathbf{X}))).$$

现在将求导式稍作调整,改为

$$(2\mathbf{I} + \mu^{(t)} \mathbf{D}^T \mathbf{D}) \mathbf{T} = 2\hat{\mathbf{T}} + \mu^{(t)} \mathbf{D}^T \left(\mathbf{G}^{(t)} - \frac{\mathbf{Z}^{(t)}}{\mu^{(t)}} \right),$$

其中 \mathbf{I} 是具有适当大小的单位矩阵.立刻使用 2D-FFT 工具求解上式,推有

$$\mathbf{T}^{t+1} \leftarrow \mathcal{F}^{-1} \left(\frac{\mathcal{F} \left(2\hat{\mathbf{T}} + \mu^{(t)} \mathbf{D}^T \left(\mathbf{G}^{(t)} - \frac{\mathbf{Z}^{(t)}}{\mu^{(t)}} \right) \right)}{2\mathbf{I} + \mu^{(t)} \sum_{d \in \{h, v\}} \overline{\mathcal{F}(\mathbf{D}_d)} \circ \mathcal{F}(\mathbf{D}_d)} \right).$$

2.1.2 代码实现

需要将 2.1.1 节末尾的迭代公式转换为 MATLAB 代码.

首先,定义数值差分算子 $\mathbf{D} = \begin{bmatrix} \mathbf{D}_h^T & \mathbf{D}_v^T \end{bmatrix}^T = \begin{bmatrix} \mathbf{D}_h \\ \mathbf{D}_v \end{bmatrix}$, 其转置 $\mathbf{D}^T = \begin{bmatrix} \mathbf{D}_h^T & \mathbf{D}_v^T \end{bmatrix}$.

然后定义一个计算矩阵 $\mathbf{D}^T \mathbf{G}$ 的函数. 这里首先要解释一件事情. 对于输入的图像矩阵 \mathbf{T} , 标记其 size 为 $M \times N$. 那么 $\nabla \mathbf{T}$ 的 size 应该是 $2M \times N$. 这是因为 ∇ 导数滤波器包含图像的水平导数滤波器 ∇_h 和竖直导数滤波器 ∇_v , 其中 h, v 是水平与竖直的英文首字母. 注意 \mathbf{G} 是逼近 $\nabla \mathbf{T}$ 的参数, 因此 \mathbf{G} 的 size 也应该是 $2M \times N$. 在数学理解上, size 的具体细节无需关心, 因为公式的推导默认各种矩阵乘法和求导操作等成立. 但是对于编写代码, 这些细节需要被关心.

现在要做的是搭建函数 "myDT", 其输出结果为图像梯度近似矩阵 \mathbf{G} 被数值导数矩阵 \mathbf{D}^T 作用后的结果矩阵 $\mathbf{D}^T \mathbf{G}$. 按

照此前说明的, $\mathbf{G} = \begin{bmatrix} \mathbf{G}_h \\ \mathbf{G}_v \end{bmatrix} \in \mathbb{R}^{2M \times N}$. 则

$$\mathbf{D}^T \mathbf{G} = \begin{bmatrix} \mathbf{D}_h^T & \mathbf{D}_v^T \end{bmatrix} \begin{bmatrix} \mathbf{G}_h \\ \mathbf{G}_v \end{bmatrix} = \mathbf{D}_h^T \mathbf{G}_h + \mathbf{D}_v^T \mathbf{G}_v.$$

向前差分的二维卷积核分别是

$$d_h := [1 \quad -1 \quad 0], d_v = \begin{bmatrix} 1 \\ -1 \\ 0 \end{bmatrix}.$$

而对于向量 x , 有 $\mathbf{D}_h(x) = \text{vec}(\mathbf{X} * d_h)$ 成立, 相应的是 $\mathbf{D}_h^T(x) = \text{vec}(\mathbf{X} * d_h^f)$, 其中

$$d_h^f := [0 \quad -1 \quad 1], d_v^f = \begin{bmatrix} 0 \\ -1 \\ 1 \end{bmatrix},$$

上标符号 f 表示卷积的翻转操作, 即将卷积核水平翻转一次, 然后竖直翻转一次. MATLAB 自带了 "flip" 函数用于数组的翻转.

只是要注意, 差分矩阵使用的前提假设是图像具有循环边界, 在循环边界假设下, 需要对图像进行边缘延拓处理. 具体的说是以下的 "myExtend" 函数

```
function [tildeTh,tildeTv]=myExtend(T,k)
    if k==1
        tildeTh=[T,T(:,1)];
        tildeTv=[T;T(1,:)];
    elseif k== -1
        tildeTh=[T(:,1),T];
        tildeTv=[T(1,:);T];
    end
end
```


这里 $\tilde{\mathbf{T}}_h, \tilde{\mathbf{T}}_v$ 分别是 \mathbf{T} 沿水平和竖直方向周期延拓的矩阵.

还需要截取延拓后的矩阵为原大小.

```
function [limitTh,limitTv]=myLimit(T,k)
    if k==1
        limitTh=T(:,1:end-1);
        limitTv=T(1:end-1,:);
    elseif k== -1
        limitTh=T(:,2:end);
        limitTv=T(2:end,:);
    end
end
```

现在制作转置前向差分算子 \mathbf{D}^T 的计算函数"myDT".

```
function [DG]=myDT(G)
    %G 的 size 是 2M*N, 定义 p=2M
    [p,n]=size(G);
    %向下取整获得参数 M, 也许应该说是 m, 但我想符号大小写问题不影响理解
    m=floor(p/2);
    %将矩阵 G 向量化为 g, 并切割 g 的水平方向与竖直方向, 重塑为水平梯度近似矩阵 Gx, 竖直梯度近似
    矩阵 Gy
    g=reshape(G,[p*n,1]);
    Gh=reshape(g(1:m*n),[m,n]);
    Gv=reshape(g(m*n+1:p*n),[m,n]);
    [tildeGh,~]=myExtend(Gh,-1);
    [~,tildeGv]=myExtend(Gv,-1);
    %创建卷积核
    dxf=[0,-1,1];
    dyf=[0;-1;1];
    %卷积操作
    tildeDGh=conv2(tildeGh,dxf,'same');
    tildeDGv=conv2(tildeGv,dyf,'same');
    [DGh,~]=myLimit(tildeDGh,-1);
    [~,DGv]=myLimit(tildeDGv,-1);
    %返回结果
    DG=DGh+DGv;
end
```

现在编写用 2D-FFT 操作迭代更新参数 \mathbf{T} 的函数. 首先计算的是

$$\sum_{d \in \{h,v\}} \overline{\mathcal{F}(\mathbf{D}_d)} \circ \mathcal{F}(\mathbf{D}_d).$$

注意 \mathbf{D}_d 对应于导数滤波器的卷积核 d_h, d_v . 将卷积核扩展到 X 的大小后, 有等式

$$\overline{\mathcal{F}(\mathbf{D})} \circ \mathcal{F}(\mathbf{D}) = \overline{\mathcal{F}(d)} \circ \mathcal{F}(d)$$

成立.

```
function [result]=myFD(m,n)
    %创建卷积核
    dx=[1,-1,0];
    dy=[1;-1;0];
    %填充零元素使得卷积核与图像大小一致
    dx_padded=zeros(m,n);
    dy_padded=zeros(m,n);
    dx_padded(2,1:3)=dx;
    dy_padded(1:3,2)=dy;
    %进行 FFT 计算
    FDx=fftshift(fft2(dx_padded));
    FDy=fftshift(fft2(dy_padded));
    %计算点元素乘积
    FDx_norm=conj(FDx).*FDx;
    FDy_norm=conj(FDy).*FDy;
    %返回结果
    result=FDx_norm+FDy_norm;
end
```

编写迭代函数.其中方便起见,使用 \mathbf{U} 标记 $\mu^{-1}\mathbf{Z}$.

```
function [T] = myUpdateT(Ti,mu,G,U)
    %Ti 是 T 的迭代初值
    %U=Z/mu,G,Z,mu 是优化参数
    X=G-U;
    DTX=myDT(X);
    Tnum=2*Ti+mu*DTX;
    Tn=fftshift(fft2(Tnum));
    [m,n]=size (Ti);
    Td=2+mu*myFD(m,n);
    Tnd=Tn./Td;
    %迭代结果输出为 T
    T=ifft2(ifftshift(Tnd));
end
```

2.2 \mathbf{G} 子问题与 \mathbf{Z} , μ 参数的调整

解决完 \mathbf{T} 参数的迭代问题后,现在将 \mathbf{G} 参数的迭代问题一并解决.

2.2.1 公式的导出

将与 \mathbf{G} 无关的项去掉后,得到以下优化问题:

$$\mathbf{G}^{(t+1)} \leftarrow \underset{\mathbf{G}}{\operatorname{argmin}} \alpha \|\mathbf{W} \circ \mathbf{G}\|_1 + \Phi(\mathbf{Z}^{(t)}, \nabla \mathbf{T}^{(t+1)} - \mathbf{G}).$$

求导后,类似于 LASSO 问题,闭式解如下:

$$\mathbf{G}^{(t+1)} = \mathcal{S}_{\frac{\alpha \mathbf{W}}{\mu^{(t)}}} \left[\nabla \mathbf{T}^{(t+1)} + \frac{\mathbf{Z}^{(t)}}{\mu^{(t)}} \right],$$

如同课本中介绍的那样,这里 $\mathcal{S}_{\varepsilon>0}[\cdot]$ 表示收缩算子,其在标量上的定义是:

$$\mathcal{S}_{\varepsilon}[x] = \text{sgn}(x) \max(|x| - \varepsilon, 0).$$

将收缩算子扩展到向量和矩阵上,表示为对数据元素进行逐个处理.例如 $\mathcal{S}_{\mathbf{A}}[\mathbf{X}]$ 对 \mathbf{X} 的元素进行逐个收缩,阈值由相应的条件 \mathbf{A} 给出.

```
function [S] = myShrinkage(A,X)
    %A 是条件矩阵,X 是被收缩的矩阵
    %输出结果 S
    [m,n]=size(A);
    Z=zeros(m,n);
    S=sign(X).*max(abs(X)-A,Z);
end
```

接下来,按照增广乘子方法的一般迭代算法更新参数 \mathbf{Z}, μ .即

$$\begin{aligned} \mathbf{Z}^{(t+1)} &\leftarrow \mathbf{Z}^{(t)} + \mu^{(t)}(\nabla \mathbf{T}^{(t+1)} - \mathbf{G}^{(t+1)}); \\ \mu^{(t+1)} &\leftarrow \mu^{(t)} \rho, \rho > 1, \end{aligned}$$

其中 ρ 是事先设置的罚因子增长参数.

2.2.1 照明矩阵最优化过程代码

现在可以给出全部的迭代过程的代码了,不过使用到了一个后续才会编写的权重矩阵函数"make_weight_matrix".

```
function [Topt] = myTrial(Ti,alpha,mu0,rho)
    %Ti 是初始照明图
    %alpha, mu0, rho 是相应求解参数
    %输出 Topt 是最优照明图

    [m,n]=size(Ti);
    %确定最大循环次数 k0
    k0=50;
    %参数初始化
    Z=zeros(2*m,n);
    G=Z;
    k=0;
    mu=mu0;

    %{
    % 第一种权重设置方法
    W=Z+1;
    %}

    %第二种权重设置方法
    W=myWThree(Ti,5);
```

```

while k<k0
    U=Z/mu; A=alpha*W/mu;
    %T 子问题迭代
    T=myUpdateT(Ti,mu,G,U);
    DT=myD(T);
    %G 子问题迭代
    G=myShrinkage(A,(DT+U));
    B=DT-G;
    %增广因子迭代
    Z=mu*(B+U);
    mu=mu*rho;
    k=k+1;
end
Topt=T;
end

```

这里用到一个计算 ∇T 的函数"myD".

```

function [DT]=myD(T)
    [m,n]=size(T);
    p=2*m;
    dx=[1,-1,0];
    dy=[1;-1;0];
    [tildeTh,tildeTv]=myExtend(T,1);
    [DX,~]=myLimit(conv2(tildeTh,dx,'same'),1);
    [~,DY]=myLimit(conv2(tildeTv,dy,'same'),1);
    Dx=myVec(DX);
    Dy=myVec(DY);
    DT=reshape([Dx;Dy],[p,n]);
end

```

第 3 部分 权重矩阵 \mathbf{W} 的确定

目前为止,有关参数优化的问题已经告一段落.只剩下参数 \mathbf{W} 和 α 尚未确定. α 作为一个正实轴上的滑动参数,可以进行自由调整,而 \mathbf{W} 作为 $\mathbb{R}^{2M \times N}$ 矩阵,则较为笨重,必须给出一种策略对其赋值.

注意, $\mathbf{W} = \begin{bmatrix} \mathbf{W}_h \\ \mathbf{W}_v \end{bmatrix}$.

3.1 不同的加权策略

沿用参考论文中的办法,这里讨论三种不同的加权策略,但实际操作时只考虑其中的一种.

3.1.1 全 1 的权重矩阵

此时 $\mathbf{W}(i, j) \equiv 1, \forall i, j$. 代码实现为

```

function [W]=myWOne(p,n)
    W=ones(p,n);

```

end

3.1.2 照明图梯度作为权重

此时 $W(i, j) = \frac{1}{\widehat{DT}(i, j) + \epsilon}$, $\forall i, j$, 而 ϵ 是防止分母为 0 的适当小的常数. 代码实现为

```
function [W]=myWTwo(Ti,p,n)
    W=zeros(p,n);
    varepsilon=1e-5;
    DTi=myD(Ti);
    for i=1:p
        for j=1:n
            W(i,j)=1/(DTi(i,j)+varepsilon);
        end
    end
end
```

3.1.3 高斯滤波

对于每个位置,通过以下方式设置权重:

$$W_h(x) \leftarrow \sum_{y \in \Omega(x)} \frac{G_\sigma(x, y)}{\left| \sum_{y \in \Omega(x)} G_\sigma(x, y) \nabla_h \hat{T}(y) \right| + \epsilon},$$
$$W_v(x) \leftarrow \sum_{y \in \Omega(x)} \frac{G_\sigma(x, y)}{\left| \sum_{y \in \Omega(x)} G_\sigma(x, y) \nabla_v \hat{T}(y) \right| + \epsilon}$$

其中 $G_\sigma(x, y)$ 是使用标准差 σ 的高斯核生成的. 形式上, $G_\sigma(x, y)$ 表示为:

$$G_\sigma(x, y) \propto \exp\left(-\frac{\text{dist}(x, y)}{2\sigma^2}\right)$$

其中函数 `dist` 是通常的距离函数.

实际上,第二个加权策略是该策略的一个实例. 当 $\sigma \rightarrow 0^+$ 时,两个策略得到相同的权重矩阵. 我们注意到,与 RTV 不同,我们的权重矩阵是基于给定的 \hat{T} 构建的,而不是根据 T 迭代更新的. 这意味着 W 只需要计算一次.

```
function [W]=myWThree(Ti,ker_size)
    %ker_size is the size of the Gaussian kernel
    %W is the required weight matrix
    [m,n]=size(Ti);
    p=m*n;
    %obtaining gradient of Ti
    DTi=myD(Ti);
    dtvec=myVec(DTi);
    %separating parts used for W_x and W_y
    dtx=dtvec(1:p);
```

```

dty=dtvec(p+1:2*p);
%obtaining W_x and W_y
w_gauss = fspecial ('gaussian', [ker_size,1], 2);
convl_x = conv(dtx, w_gauss, 'same');
convl_y = conv(dty, w_gauss, 'same');
varepsilon=1e-5;
W_x = 1./(abs(convl_x)+varepsilon);
W_y = 1./(abs(convl_y)+varepsilon);
%concatenating W_x and W_y to get W
W_vec = vertcat(W_x, W_y);
W = reshape (W_vec, [2*m,n]);
end

```

第 4 部分 加速运算

由于

$$\lim_{\varepsilon \rightarrow 0^+} \sum_x \sum_{d \in \{h,v\}} \frac{W_d(x) (\nabla_d \mathbf{T}(x))^2}{|\nabla_d \mathbf{T}(x)| + \varepsilon} = \|\mathbf{W} \circ \nabla \mathbf{T}\|_1,$$

标记和 x 有关的常函数 $A_d x := \frac{\alpha W_d(x)}{|\nabla_d \hat{\mathbf{T}}(x)| + \varepsilon}$, 实际只要考虑 $(\nabla_d L(x))^2$. 这是因为优化问题是

$$\min_{\mathbf{T}} \|\hat{\mathbf{T}} - \mathbf{T}\|_F^2 + \alpha \|\mathbf{W} \circ \nabla \mathbf{T}\|_1,$$

第一项保证了 \mathbf{T} 接近于 $\hat{\mathbf{T}}$, 因而它们的梯度也应该接近. 何况如果以迭代后的照明图作为新的初始照明图, 这个差距可以进一步缩小.

优化问题现在改为

$$\min_{\mathbf{T}} \|\hat{\mathbf{T}} - \mathbf{T}\|_F^2 + \sum_x \sum_{d \in \{h,v\}} A_d(x) (\nabla_d \mathbf{T}(x))^2,$$

求导后得到下面的公式

$$\left(\mathbf{I} + \sum_{d \in \{u,v\}} \mathbf{D}_d^T \text{diag}(a_d) \mathbf{D}_d \right) \mathbf{t} = \hat{\mathbf{t}}$$

其中小写字母代表向量化后的矩阵, 例如 $\mathbf{t} = \text{vec}(\mathbf{T})$. 虽然上式足够简单, 但是显而易见计算量极为巨大.

%这个神奇的代码是意外所得, 希望它的效果会好.

%出了点问题, 但主线任务用不到这个算法, 暂且搁置

function out = solveLinearEquation(in, wx, wy, lambda)

%wx,wy 是权重矩阵的水平与竖直部分

%lambda 是参数, 类似于本文的 alpha

[h,w,c] = size(in);

n = h*w;

wx = wx(:);


```

wy = wy(:);

ux = padarray(wx, h, 'pre'); ux = ux(1:end-h);
uy = padarray(wy, 1, 'pre'); uy = uy(1:end-1);
D = wx+ux+wy+uy;
B = spdiags([-wx, -wy],[-h,-1],n,n);
L = B + B' + spdiags(D, 0, n, n);    % a sparse five-point Laplacian matrix

A = speye(n) + lambda*L;
if exist('ichol','builtin')
    F = ichol(A,struct('michol','on'));
    out = in;
    for i=1:c
        tin = in(:, :, i);
        [tout, ~] = pcg(A, tin(:), 0.1, 100, F, F');
        out(:, :, i) = reshape(tout, h, w);
    end
else
    out = in;
    for i=1:c
        tin = in(:, :, i);
        tout = A\tin(:);
        out(:, :, i) = reshape(tout, h, w);
    end
end
end
end

```

可以编写一个新的最优参数获取函数了。

```

function [Topt] = myNewQuick(Ti,alpha)
[m,~]=size(Ti);
W=myWThree(Ti,5);
DTi=myD(Ti);
abs_delTi=abs(DTi);
varepsilon=1e-5;
A=alpha*(W./(abs_delTi+varepsilon));
Ax=A(1:m,:);
Ay=A(m+1:end,:);
Topt=solveLinearEquation(Ti,Ax,Ay,1);
end

```

第五部分 γ 变换后的图像

还可以通过伽马变换来操作光照图,即 $T \leftarrow T^\gamma$.

```

function [newTi]=gammaResult(Ti,gamma)
Ti=abs(Ti);
newTi=Ti.^gamma;
end

```

其余的自定义函数

```
function [x]=myVec(X)
    %对应于 vec 算子
    x=reshape(X,[],1);
end

function [lightingImg,max_RGB] = myLighting(testImg)
    %获取初始照明
    %testImg 是初始输入图像
    %lightingImg 是初始照明图像
    %max_RGB 是三个通道的最大值
    max_RGB = max(testImg, [], 3);
    %将 0 值替换为充分小的常数,以免被除数中出现 0
    varepsilon=1e-5;
    max_RGB(max_RGB == 0) = varepsilon;
    %使用 repmat 函数,生成所有像素的通道数值为最大通道数值的照明图.
    lightingImg=repmat(max_RGB,[1,1,3]);
end
```